

Descripción y Formulación del Objetivo

Predicción de fallas en equipos mediante técnicas de Aprendizaje Automático

1. Descripción del Proyecto

El presente proyecto aborda la problemática del mantenimiento de equipos técnicos desde una perspectiva basada en datos, incorporando técnicas de Aprendizaje Automático para anticipar la ocurrencia de fallas.

En contextos de soporte técnico, es frecuente que los equipos presenten fallas de forma imprevista, generando interrupciones en el servicio y una mayor demanda de intervenciones urgentes. Desde la experiencia práctica en este ámbito, se observa que el enfoque predominante es de tipo reactivo, actuando una vez que el problema ya ha ocurrido, lo cual impacta negativamente en los tiempos de respuesta, la continuidad operativa y la gestión de recursos.

Frente a este escenario, surge la necesidad de evolucionar hacia un enfoque preventivo que permita anticipar fallas antes de que se manifiesten. En este sentido, el uso de modelos de Aprendizaje Automático posibilita identificar patrones en datos históricos y variables operativas de los equipos, transformando la información disponible en un insumo estratégico para la toma de decisiones.

El proyecto propone el desarrollo de un modelo de clasificación orientado no solo a predecir la ocurrencia de fallas, sino también a aportar criterios que contribuyan a la priorización de intervenciones técnicas en entornos donde la demanda es constante y los recursos son limitados.

Para ello, se utilizará el dataset AI4I 2020 Predictive Maintenance, el cual contiene variables relacionadas con sensores industriales y condiciones de funcionamiento. Si bien se trata de un dataset de carácter público, su aplicación en este trabajo se orienta a replicar problemáticas reales del área de soporte técnico, integrando un enfoque práctico basado en la experiencia profesional.

2. Objetivo General

Desarrollar un modelo de Aprendizaje Automático capaz de anticipar la ocurrencia de fallas en equipos técnicos, con el fin de mejorar la toma de decisiones en la planificación del mantenimiento preventivo y contribuir a la reducción de intervenciones correctivas.

3. Objetivos Específicos

- Analizar la estructura y características del dataset seleccionado, identificando variables relevantes en el comportamiento de los equipos.
- Realizar el preprocesamiento de los datos, incluyendo limpieza, transformación y codificación de variables necesarias para el modelado.
- Implementar y entrenar distintos modelos de clasificación utilizando la librería scikit-learn, evaluando su desempeño en la predicción de fallas.
- Evaluar los modelos mediante métricas como accuracy, precision, recall y F1-score, priorizando la capacidad de detectar fallas reales (recall) debido al impacto crítico que implica no anticipar una falla en entornos operativos.
- Comparar los resultados obtenidos y seleccionar el modelo más adecuado considerando tanto su rendimiento predictivo como su aplicabilidad en contextos técnicos.
- Analizar la importancia de las variables para interpretar el comportamiento del modelo y su aporte a la toma de decisiones.
- Explorar cómo los resultados del modelo pueden contribuir a la priorización de tareas de mantenimiento en entornos con alta demanda de soporte técnico.

4. Contexto y Relevancia del Problema

En entornos de soporte técnico y mantenimiento de equipos, la continuidad operativa depende en gran medida de la capacidad para gestionar fallas de manera eficiente. En la práctica, es habitual que los equipos presenten problemas sin previo aviso, lo que obliga a realizar intervenciones correctivas urgentes que afectan tanto la disponibilidad del servicio como la organización del trabajo técnico.

Desde la experiencia en este tipo de entornos, donde la demanda de soporte es constante, la gestión reactiva no solo incrementa los tiempos de inactividad, sino

que también dificulta la planificación de tareas, genera sobrecarga operativa y reduce la eficiencia en la asignación de recursos. En particular, la falta de mecanismos que permitan anticipar fallas limita la posibilidad de establecer prioridades basadas en el riesgo y el impacto real de cada incidente.

En este contexto, la incorporación de técnicas de Aprendizaje Automático representa una oportunidad para transformar datos históricos en herramientas de apoyo a la toma de decisiones. A través del análisis de variables operativas y condiciones de funcionamiento, es posible identificar patrones asociados al comportamiento de los equipos y estimar la probabilidad de falla antes de que esta ocurra.

La relevancia de este enfoque no se limita únicamente a la mejora en la precisión predictiva, sino también a su impacto en la gestión del mantenimiento. La posibilidad de anticipar fallas permite avanzar hacia un modelo preventivo, donde las intervenciones pueden planificarse en función del nivel de riesgo, optimizando tiempos, reduciendo interrupciones y mejorando la calidad del servicio brindado.

Asimismo, en entornos con múltiples equipos y recursos limitados, contar con herramientas que permitan priorizar acciones técnicas en base a datos resulta clave para mejorar la eficiencia operativa. En este sentido, el modelo propuesto no solo busca resolver un problema de predicción, sino también aportar valor en la toma de decisiones, alineando el análisis de datos con necesidades reales del área de soporte técnico.

5. Tipo de Problema

El problema planteado corresponde a un caso de clasificación supervisada, en el cual el modelo debe predecir si un equipo presentará una falla o no en función de distintas variables de entrada.

La variable objetivo será de tipo binaria:

- 0: No presenta falla
- 1: Presenta falla

6. Modelos a Utilizar

Para la resolución del problema se evaluarán distintos algoritmos de clasificación disponibles en la librería **scikit-learn**, entre ellos:

- **Regresión Logística:** utilizada como modelo base por su simplicidad e interpretabilidad.
- **Árbol de Decisión:** permite identificar relaciones no lineales entre variables.
- **Random Forest:** considerado el modelo principal debido a su robustez y capacidad para mejorar la precisión mediante el uso de múltiples árboles.
- **K-Nearest Neighbors (KNN):** utilizado como modelo alternativo basado en la similitud entre observaciones.

El dataset será dividido en conjuntos de entrenamiento y prueba para validar el desempeño del modelo. La selección final se realizará en función de las métricas obtenidas y su capacidad de generalización, priorizando modelos que logren un equilibrio entre rendimiento predictivo e interpretabilidad.